



Optimización de Cartera Financiera mediante Aprendizaje Profundo

Resumen Ejecutivo

Autor: Amadeo Gustavo Ancarani

Director: Jorge Linde Díaz

Máster Universitario en Ciencia de Datos (2021-2022)

Madrid, 7 de junio 2022

1. ABSTRACT

Este documento resume el trabajo realizado en el desarrollo del proyecto. El principal objetivo de éste era la implementación de un sistema que realice, a través de redes neuronales, una optimización del portafolio financiero de una persona. Esta meta ha sido lograda, aunque sin obtener los resultados esperados en comparación a la metodología desarrollada por Markowitz.

Es necesario destacar que el pico más bajo ha sido presentado por la metodología tradicional, con lo cual el sistema implementado conlleva a una seguridad mayor en épocas de turbulencia financiera.

Finalmente, el hecho de probar ajustar mediante algoritmos avanzados de predicción como los son las redes neuronales al área de las finanzas con propuestas novedosas pueden prometer logros para una tarea tan compleja como es la determinación de qué acciones comprar y qué cantidades comprar cada semana o incluso períodos mucho más corto-placistas.

En estos tiempos de gran incertidumbre cada herramienta cuenta, y las metodologías actuales se deben complementar a formas testeadas en el tiempo que, por más que se han desarrollado hace tiempo, siguen en vigencia dada su efectividad.

2. INTRODUCCIÓN

El presente Trabajo Fin de Máster (TFM) tiene por objetivo final la implementación de una optimización de carteras de activos financieros mediante la utilización de algoritmos de aprendizaje profundo.

Es necesario remarcar que no se trata de una recomendación de inversión ya que se trata de un ejercicio académico con el fin de implementar conocimientos obtenidos a lo largo del Máster en Ciencia de Datos para el período 2021-2022.

A modo simplificado es posible describir al proceso por las siguientes etapas:

- En el desarrollo del trabajo se seleccionan, a través de una red neuronal Autoencoder, 5 acciones que cumplan con ciertos requisitos.

- Luego, se capta la información de los últimos 300 períodos de las acciones seleccionadas para estimar los rendimientos de los próximos 5 períodos a través de una segunda red neuronal del tipo LSTM.
- Con estos rendimientos estimados, se obtienen los pesos relativos de cada acción en la cartera para los próximos 5 períodos a través de una tercera red neuronal con una función de pérdida personalizada.

Este TFM plantea un desafío destacable en mi opinión puesto que requiere el manejo de múltiples arquitecturas de redes neuronales, además de conocimientos relacionados a las finanzas y a la valuación de acciones.

A modo de resumen, se presenta la secuencia en formato gráfico:

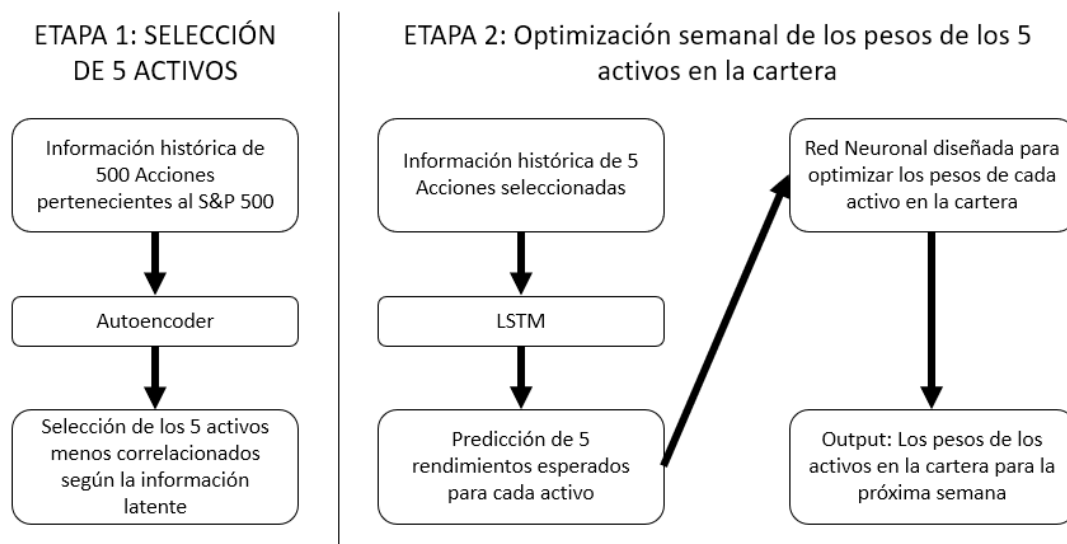


Figura 1: Desarrollo del TFM. Fuente: Elaboración propia.

3. MARCO TEÓRICO

3.1. INTRODUCCIÓN A LA INVERSIÓN EN ACTIVOS FINANCIEROS

Un activo financiero es un documento o título emitido por una empresa, o banco, o institución privada o pública, cuyo comprador o propietario obtiene los derechos plasmados en el mismo.

La rentabilidad es la ganancia obtenida al invertir, se presentan en proporción a la inversión realizada, por ejemplo: 15% anual, 1,95% mensual, 0,005% diario, etc.

Riesgo significa incertidumbre y, en términos financieros, se considera que incorpora el mismo riesgo obtener un 20 % por encima o por debajo de la rentabilidad prevista. El riesgo financiero es el conjunto de factores que pueden

hacer que la rentabilidad de una inversión sea distinta a la esperada, por encima o por debajo.

3.2. INTRODUCCIÓN A LAS TÉCNICAS CLÁSICAS DE OPTIMIZACIÓN DE CARTERAS DE INVERSIÓN

3.2.1. TEORÍA MODERNA DEL PORTAFOLIO

Teoría moderna de portafolio (MPT por sus siglas en inglés) es una teoría de Finanzas, originada por Harry Markowitz en 1952, que intenta maximizar la cartera esperada retorno para una cantidad dada de riesgo de la cartera, o minimizar el equivalente riesgo para un determinado nivel de rentabilidad esperada, eligiendo cuidadosamente las proporciones de varios activos.

Un supuesto central en este análisis es la idea el inversionista busca en todo momento maximizar el valor descontado de los futuros rendimientos esperados por los activos. Lo destacable de este punto es que no es necesario investigar la forma de la distribución de probabilidad, simplemente este marco teórico consiste en una regla razonablemente simple: el inversionista considera deseable el retorno esperado e indeseable la varianza de estos retornos (riesgo).

Donde w_i es la participación relativa de cada acción, mientras que $E(R_i)$ es el rendimiento esperado de cada activo:

$$E(R_p) = \sum_{i=1}^n w_i E(R_i)$$

Y la varianza del portafolio (V) es definida como:

$$\sigma_p^2 = \sum_{i=1}^n w_i^2 \sigma_i^2 + \sum_{i=1}^n \sum_{j \neq i}^n w_i w_j \sigma_i \sigma_j \rho_{ij}$$

Donde ρ_{ij} es denominado el coeficiente de correlación entre los distintos activos que componen el portafolio.

Restricciones:

$$\sum_{i=1}^n w_i = 1$$
$$w_i \geq 0$$

3.2.1.1. DIVERSIFICACIÓN

Los inversionistas pueden reducir su exposición al riesgo activo individual mediante la diversificación de la cartera de activos. La diversificación genera la

posibilidad de mantener la rentabilidad esperada con una menor incertidumbre asociada.

3.2.2. LA FRONTERA EFICIENTE




Figura 2: Frontera Eficiente de selección de Portafolio. Fuente: Forbes

En el gráfico anterior se presentan los activos individuales en función del retorno esperado (retornos) y la desviación estándar (riesgo).

A partir de las distintas combinaciones posibles de los activos individuales en la cartera, se logra generar la frontera eficiente. Es llamada de esta forma ya que cualquier punto dentro de esta frontera se tratan de carteras ineficientes puesto que se pueden igualar los retornos disminuyendo el riesgo o igualmente se puede aumentar los retornos manteniendo el riesgo.

El límite izquierdo de esta hipérbola a partir del punto en el cual se modifica la pendiente se trata de la cartera de mínimo riesgo posible. Luego, en el borde superior de esta región es la frontera eficiente en la ausencia de un activo libre de riesgo.

Uno de los posibles resultados de esta teoría establece que, si se considera una tasa de retorno libre de riesgo, se puede trazar una recta que genere un punto de tangencia con la frontera eficiente y, de esta manera, se obtiene el portafolio óptimo.

4. DESARROLLO DE LOS MODELOS

Para el desarrollo de los modelos planteados se han captado los precios diarios de cierre de mercado para las acciones que conforman el S&P500. Se tratan de 504 acciones con información desde 02/01/2009 hasta 31/01/2022.

Esto genera una matriz de 3286 filas (precios observados) y 504 columnas (acciones). Estos datos se separaron en tres bloques llamados entrenamiento,

validación y test. El conjunto de entrenamiento capta el 70% inicial de los datos, el de validación el 15% siguiente y el de test con el 15% final.

4.1. ETAPA 1

En este primer bloque se buscó implementar una arquitectura Autoencoder con el objetivo de reducir la información de 3286 retornos diarios de cada activo (504) a una matriz que se represente en el 10% de los días utilizados, es decir 328 valores para cada acción.




Figura 3: Proceso de la red Autoencoder. Fuente: Elaboración propia.

Con la información de la matriz latente obtenida, se calcularon las correlaciones de los activos para lograr obtener la cartera de 5 activos con menor correlación posible.

La motivación de realizar esta metodología alternativa proviene del hecho que realizar un simple cálculo de correlación entre los activos a través de la fórmula propuesta por Karl Pearson (la comúnmente utilizada), solo mide la dependencia lineal entre dos variables. Es más, en el caso de variables con dependencia temporal, este indicador sólo puede observar relaciones en el mismo período de tiempo, entonces, si se trata de una dependencia con cierto desfase en el tiempo, esta medida no es capaz de captarlo.

Lo que se buscó con esta transformación de los inputs del cálculo del índice correlación fue introducir un resumen de los más de 3000 datos diarios a poco más de 300 datos con la detección de posibles relaciones no lineales a través de una red neuronal.

De esta manera, se intenta lograr obtener a la cartera financiera lo menos correlacionada posible para lograr obtener todos los beneficios mencionados anteriormente sobre la diversificación de los activos que conforman al portfolio.

De este proceso se obtuvo que la cartera resultante está conformada por:

- **IVZ:** Invesco Ltd. es una empresa independiente de gestión de inversiones.
- **JBHT:** JB Hunt Transport Services, Inc. es una empresa de transporte y logística.
- **J:** Jacobs Engineering Group Inc. es una empresa de servicios técnicos profesionales.
- **ITW:** Illinois Tool Works Inc. es una empresa que produce componentes diseñados, equipos y sistemas consumibles y productos especiales.
- **JCI:** Johnson Controls International es un conglomerado que produce equipos contra incendios y de seguridad para edificios.

Como se puede destacar, se tratan de empresas relacionadas a mundos completamente diferentes y cuya poca correlación tiene lógica desde el aspecto analítico.

4.2. ETAPA 2

En este bloque, con los activos seleccionados, se estimaron los próximos 5 precios siguientes con la información disponible de los últimos 300 días de cada acción. Dicha proyección se obtiene a través de una LSTM por las ventajas de estas arquitecturas de redes neuronales para el tipo de datos secuenciales con los que estamos tratando.

Por último, con las predicciones de la red LSTM, se debe obtener la combinación de los pesos de los activos en la cartera tal que se obtenga el máximo Sharpe Value, este indicador no es más que una división entre el retorno esperado de los activos y la desviación estándar de los mismos:

$$\frac{E(R_p)}{\sigma(R_p)}$$

Para ello se desarrolló una red neuronal tradicional con una función de pérdida personalizada, para que la misma red optimice este valor en su entrenamiento. Esto requiere de un conocimiento central en el manejo de matrices y la información necesaria para calcular este valor.

5. RESULTADOS

Los pesos de la cartera con el método convencional se generó con los datos de entrenamiento junto con los de validación y se obtuvo lo siguiente:

Returns	1.762235
Volatility	3.486567
IVZ weight	0.000137
JBHT weight	0.618745
J weight	0.026643
ITW weight	0.065965
JCI weight	0.288510

Figura 4: Cartera obtenida mediante la teoría clásica. Fuente: Elaboración propia, código fuente del TFM.

En el siguiente grafico se presentan en función del retorno esperado (eje Y) y la volatilidad de la cartera (eje X), todas las combinaciones obtenidas con el método de la MPT. En color rojo se destaca a la cartera de menor volatilidad y en color azul a la cartera óptima.

Por otro lado, la optimización mediante las 2 redes neuronales




Figura 5: Carteras simuladas mediante la metodología clásica. Fuente: Elaboración propia, código fuente del TFM.

implementadas para modificar semanalmente los pesos obtuvo el siguiente rendimiento en comparación con el método anterior:




Figura 6: Rendimiento en el tiempo de las carteras optimizadas mediante Redes Neuronales (línea azul) y MPT (línea naranja). Fuente: Elaboración propia, código fuente del TFM.

En color azul se presentan los resultados de las redes neuronales y en color naranja los resultados de la teoría tradicional. Vemos como la cartera tradicional es mucho más volátil que la cartera propuesta por la metodología de redes neuronales. Si bien este punto no es crucial dado que se trata de la cartera óptima propuesta por la teoría clásica, es posible que al acceder a esta información se proponga aplicar la cartera optimizada por NN en épocas de mercado a la baja, y alternar a la propuesta clásica en épocas de recuperación o bonanza económica.

Esto ya es decisión personal de cada inversor a la hora de aplicar sus fondos al mercado financiero.

El desempeño final de cada proceso es:

- Ganancia MPT: 65.17%
- Valor mínimo durante el proceso con MPT: -29.05%
- Ganancia NN: 52.39%
- Valor mínimo durante el proceso con NN: -17.73%

6. CONCLUSIONES

Hablando estrictamente de los resultados, por el momento, es verdad que no se diferencia en un gran porcentaje con respecto a la cartera de la MPT, es cuestión de probar diferentes combinaciones de la gran cantidad de hiperparámetros para los modelos de la etapa 2 (LSTM y NN tradicional). Estas combinaciones pueden otorgar resultados sumamente diferentes ante pequeños cambios y la gran cantidad de posibilidades, abre las puertas a una mejora en la eficiencia de las predicciones.

Otro cambio posible para mejorar lo realizado puede ser la modificación de la cantidad de información pasada que está leyendo cada red para ser entrenada. Estos 300 datos diarios pueden pasar a ser tanto menos como incluso más para lograr mejores predicciones.

Por último, en cuanto a mejoras posibles, si bien la implementación de un Autoencoder para realizar la selección de las variables fue un desarrollo novedoso, el hecho de no considerar proyecciones de rendimientos futuros para los activos a seleccionar puede que resultase en una selección no tan favorable. Es cuestión de agregar esta información al análisis de selección y combinar estos enfoques (combinación entre mayor retorno y menor correlación).